5. Sistemas de predicción por conjuntos, SPC

De los modelos de predicción deterministas obtenemos, para cada punto del espacio de estudio, un único valor. Es decir, al introducir los datos medidos (condiciones iniciales con las que iniciamos las simulación) , como pueden ser la temperatura y presión entre otras, estos nos dan como resultado un único estado atmosférico.

En un principio podemos pensar que estos modelos son muy potentes, que lo son, pues nos dan un **único** estado atmosférico futuro a partir de unas condiciones iniciales presentes (o pasadas). Ahora podemos preguntarnos, y comprobar empíricamente, que si esto es así **¿Por qué en múltiples ocasiones en la previsión de tiempo han dado lluvia y luego no ha llegado a llover?** ¿Si estos modelos solo nos dan cómo solución un único escenario porqué, a veces, se dan otros?.

Esto tiene una 'sencilla' respuesta, y es que como ya hemos comentado, los modelos utilizados no están exentos de errores. Este error nos va a depender tanto de los errores en las condiciones iniciales como de los errores en los parámetros del modelo. Al ser las ecuaciones a modelizar no lineales, estos errores se van propagando con el paso del tiempo en la simulación siendo este mayor a medida que el tiempo avanza. Es tal que a la hora de realizar una predicción son las más cercanas en el tiempo las que más fiabilidad tienen y a medida que avanza en el tiempo, aumenta la incertidumbre y por ende, es más sencillo equivocarse en la predicción.

Veamos un ejemplo en otro campo diferente de la meteorología, la dinámica de poblaciones. Aún no siendo el tema a tratar, nos parece intesante hacer un inciso en el tema ya que al tratarse de ecuaciones no lineales encontramos escenarios en los que tenemos caos.

Hemos elaborado un pqueño script de python en el que hemos definido un función en la que mostramos cómo evoluciona una población dados dos parámetros iniciales. Por un lado, tenemos x_0 el cual denota la población inicial del 0 al 1, donde, si por ejemplo, $x_0 = 0{,}5$ quiere decir que la población se encuentra al 50 % de su máximo. Por otro lado, tenemos el parámetro r que nos ayudará a darle un valor número al ritmo de reproducción de la población,

$$X_n = rX_0\left(1 - X_0\right).$$

Este modelo es interesante ya que tenemos dos regímenes de estudio puesto que existen valores de r para los cuáles la evolución del sistema se vuelve caótica y dejamos de tener convergencia para un t infinito. El sistema oscilará entre dos valores.

```python
def poblacion(r, x_0, cota):

    evolucion = [x_0]

    x_p = r*x_0*(1-x_0)

    evolucion.append(x_p)

    while (abs(evolucion[len(evolucion)-1] - evolucion[len(evolucion)-2])> cota):

        x = evolucion[len(evolucion) - 1]*r*(1-evolucion[len(evolucion)-1])
        evolucion.append(x)

        if len(evolucion)>500: break


    return print(f'El valor de estabilización es {evolucion[len(evolucion) - 1]}'), len(evolucion), evolucion
```

Figura 2: Función población definida en Python.

En la función que se muestra en la Figura 2 (*poblacion*) se realiza una relación de recursividad entre la población n y otra $n+1$, lo que se puede traducir cómo que calculamos una población futura a partir de una anterior o presente. La función nos devuelve un vector, *evolucion*, con los valores de X_n siempre que se hayan dado las condiciones que se imponen en la función, la de convergencia, o bien que el vector supere un cierto número de elementos (que será nuestro corte cuando el sistema no converja).

```
estabilizador1, iteraciones1, evolucion1 = poblacion(1.5, 0.5 ,10**-31)
estabilizador2, iteraciones2, evolucion2 = poblacion(1, 0.5 ,10**-31)
```

Figura 3: Valores de r para dos poblaciones en régimen no caótico.

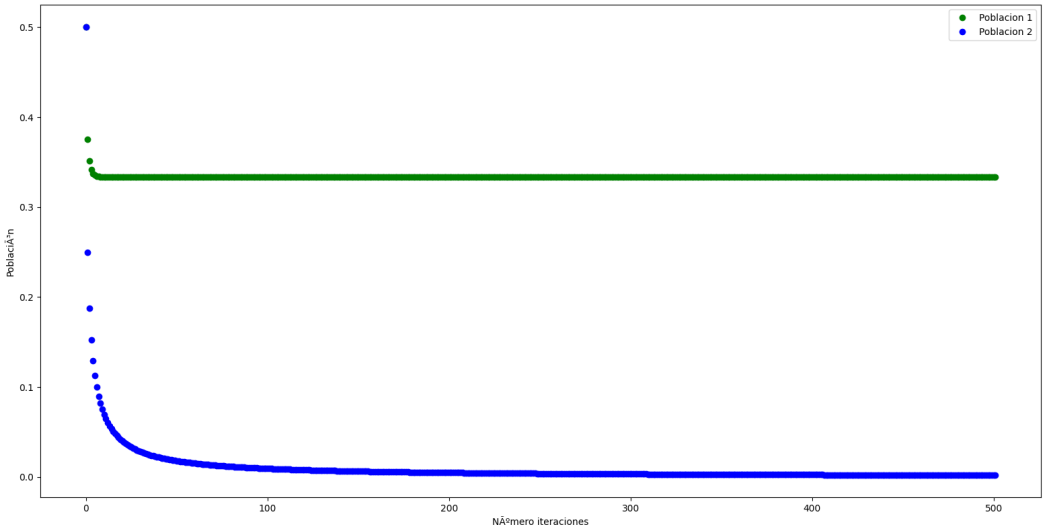

Figura 4: Población en función del tiempo (n) en régimen no caótico. Se observa que ambas poblaciones convergen a un valor de la población dados, para tiempos lo suficientemente grandes.

```
estabilizador1, iteraciones1, evolucion1 = poblacion(3, 0.5 ,10**-31)
estabilizador2, iteraciones2, evolucion2 = poblacion(3.005, 0.5 ,10**-31)
```

Figura 5: Valores de r para dos poblaciones en régimen caótico.

Dados ahora los valores de r que se muestran en la Figura 5 obtenemos la gráfica de la Figura 6. Dado el orden de la diferencia entre ambos valores de r para las distintas poblaciones, podemos considerar uno de ellos como una pequeña perturbación del otro.

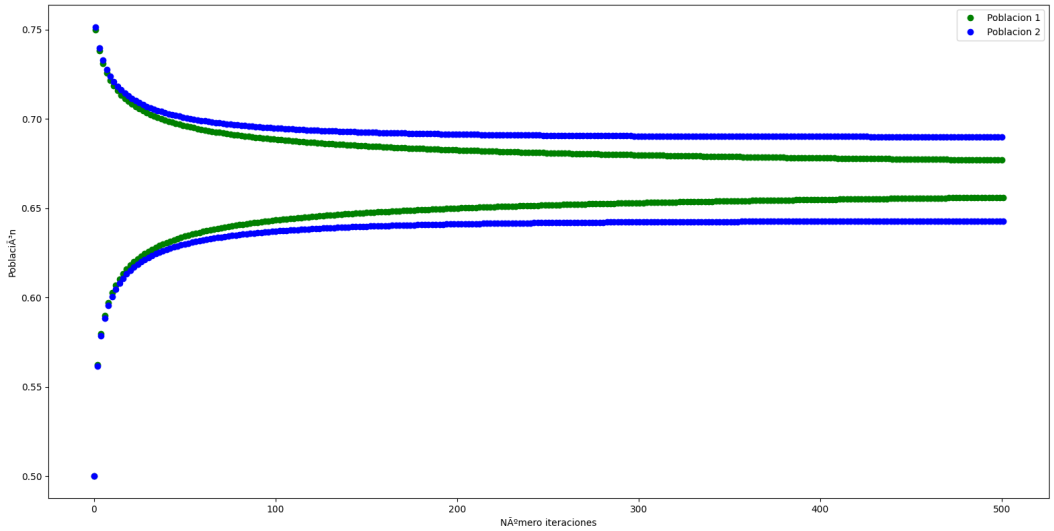

Figura 6: Población en función del tiempo (n) en régimen caótico. Se observa que ambas poblaciones no convergen para tiempos infinitos. Esto es porque las poblaciones van oscilando entre dos valores para tiempos grandes. Digamos que tenemos dos puntos de convergencia para ambas sucesiones.

Algo importante a resaltar, y uno de los principales motivos por el cuál comentamos este caso, es que la diferencia entre ambas poblaciones va incrementando a medida que avanzamos en el tiempo y además esta discrepancia se hace mayor de forma no lineal, como era de esperar.

Limitándonos a quedarnos solo con este último detalle podemos realizar una analogía con los modelos de predicción meteorológica y entender así mejor el porqué las predicciones que se realizan del tiempo van perdiendo fiabilidad a medida que nos alejamos en el tiempo.

Supongamos que la población 1, representada en la Figura 6 de color verde, es el escenario real que se da del estado atmosférico. El azul, población 2, un estado atmosférico obtenido corriendo un modelo de predicción determinista. Al igual que en el caso de la dinámica de poblaciones, las ecuaciones del modelo son no lineales con lo que pequeñas perturbaciones (errores) en los valores iniciales introducidos en el modelo nos llevará a que el sistema evolucione de forma análoga a como observamos en la Figura 6. El error introducido no será demasidado elevado para tiempos pequeños pero a medida que vayan pasando los días lo más probable es que empecemos a tener una discrepancia considerable con la realidad. Los errores se propagan de forma no lineal.

Hemos asumido que a medida que trancurre el tiempo vamos perdiendo fiabilidad en la predicción que nos proporciona un determinado modelo. Esta es más fiable para tiempos pequeños, digamos unos pocos dias. Ahora podemos preguntarnos **cómo de fiable es el estado atmosférico que nos pueda proporcionar un determinado modelo determinista**, pues a final de cuentas solo nos proporciona un único escenario. Podemos poner a prueba el modelo lanzando predicciones y en función del grado de acierto que tenga darle una mayor o menor fiabilidad, ¿no?. Lo cierto es que esto último no tiene mucho sentido pues que el modelo acierte con bastante cercania el tiempo a lo largo de una semana,

no nos garantiza que la próxima también lo vaya a hacer. Y es que no es lo mismo una atmósfera estable que una inestable, en el segundo caso tendremos mayor incertidumbre pues esteremos expuestos a mayores errores. No nos vale predecir muy bien una semana y a la siguiente no, hay en juego mucho, dinero sobretodo.

El paso de un marco determinista a uno probabilista puede ayudarnos. No dejaremos de tener error sin embargo, podremos cuantificar de cierta manera la incertidumbre. Para ello será necesario dotar a nuestro espacio de estudio una función que nos proporcione cómo se reparte la probabilidad de que un determinada variable tome un cierto valor en un punto de dicho espacio. Esto nos dará un abanico de estados atmosféricos posibles donde a cada uno le asociaremos una probabilidad.

$$\boxed{X(t_0 + t') \Longrightarrow \rho(t_0 + t')}$$

El objetivo es pasar de un único estado atmosférico $X(t_0 + t')$ a un abanico de ellos $\rho(t_0 + t')$. Para ello tendremos que tomar también un vector de valores iniciales (entorno del valor medido). Dado un valor de una determinada variable inicial, como puede ser la temperatura, correremos los modelos $n + 1$ veces , una para cada valor de temperatura, $\vec{T} = (t_0, t_1, \ldots, t_i, \ldots, t_n)$. Esto se realizará para cada una de las variables que pueda depender el modelo, no solo se realizará para la temperatura, claro está. Con todos ellos tendremos un vector local (para cada punto del espacio) $\vec{V_i} = (x_i, y_i, \ldots, z_i)$ el cuál contendrá todas las componentes i de cada una de las variables de las que depende el modelo, esto nos dará cómo resultado el estado atmosférico X_i. Corriendo el modelo para cada uno de los $\vec{V_i}$ tendremos el vector de estado atmosféricos, $\vec{X} = (X_0, X_1, \ldots, X_i, \ldots, X_n)$.

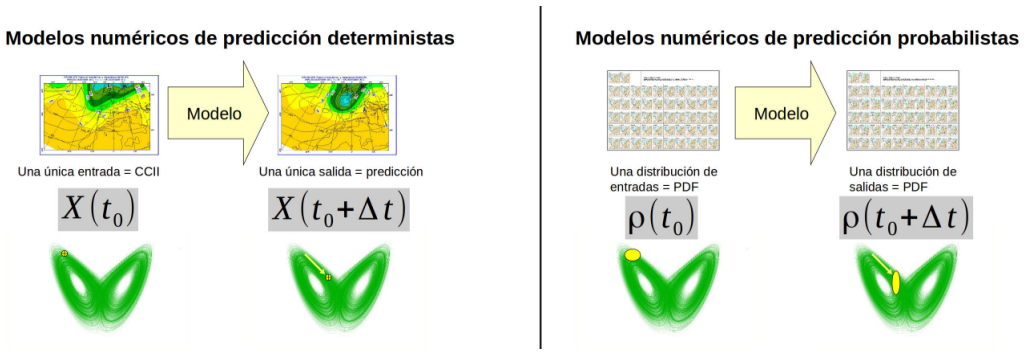

Figura 7: Paso de un esquema determinista a uno probalista. Se construye una función de densidad de probabilidad.

Entonces, dado un vector inicial, donde se concentran todos los valores iniciales para cada una de las variables independientes del modelo, si nuestro modelo depende solo de $Temperatura, Presión, Humedad = T_0, P_0, H_0$ tomaremos los vectores valores de los intervalos $[T_0 - \Delta T, T_0 + \Delta T]$, $[P_0 - \Delta P, P_0 + \Delta P]$, $[H_0 - \Delta H, H_0 + \Delta H]$. El intervalo lo partiremos en tantos valores como nosotros queramos, lo suyo sería intentar partirlo en muchos trozos, equiespaciados, para tener algo lo más parecido a un continuo. Veamos un caso en particular para explicarnos con mejor claridad.

Imaginemos que tenemos un pequeño huerto en nuestra parcela de campo y que disponemos de un sencillo modelo que nos da una predicción de la temperatura en el tiempo. Decidimos comprobar si una determinada noche las temperaturas bajaran del cero pues de ser esto así perderemos nuestra cosecha. Puesto que nuestro modelo es determinista

dado un valor de la temperatura inicial este nos devolverá un estado de la temperatura a lo largo de un intervalo de tiempo futuro, pongamos veinticuatro horas.

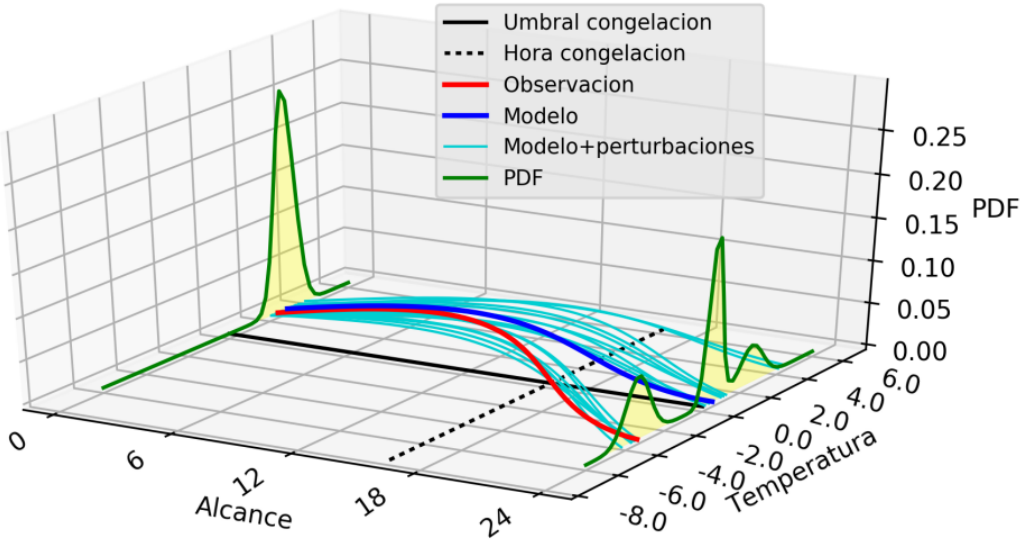

Figura 8: Evolución de la temperatura según nuestro modelo. La linea roja es la temperatura que se ha dado realmente, la azul oscuro la que nos predice nuestro modelo para el valor inicial medido con un termómetro.

En la Figura 8 se representa el modelo del que disponemos. Dado una temperatura inicial para un valor de alcance 0 obtenemos un valor, pasadas 24 horas, por encima de los cero grados y además, a lo largo de todo el tiempo ésta no bajó de los cero. Sin embargo, si observamos la line roja, que nos da el valor real, vemos que difiere bastante y en el caso de habernos fiado del modelo habriamos perdido la cosecha pues vemos que para ciertas horas la temperatura tomó valores por debajo del cero siendo a las 24 horas cercano a los -4 grados.

La linea roja de la azul no se separa demasiado para tiempo pequeños sin embargo, para tiempo más grandes ya empezamos a notar la diferencia.

Pongamos que el termómetro que utilizamos para medir la temperatura de partida, introducida en el modelo para lanzarlo, tiene una incertidumbre de $\pm 0{,}5$ grados. Podemos ahora realizar una partición del intervalo de temperaturas $[T_0 - 0{,}5; T_0 + 0{,}5]$. Tomar temperaturas en un entorno del medido y lanzar el modelo tantas veces como temperaturas diferentes tengamos. Esto nos proporcionará para cada una de las temperaturas una predicción. Las temperaturas finales no se comportarán de forma lineal, como bien sabemos ya. Es por ello que el abanico de temperaturas que obtendremos, después de correr el modelo tantas veces como hayamos partido el intervalo de temperaturas, no serán valores alrededor de un valor central. Si esto fuera así no tendría mucha gracia realizar todo este estudio pues obtendriamos siempre una densidad de probabilidad centrada en un valor, lo que viene siendo una normal, la media coincidiría con la mediana.

Como el comportamiento no es lineal, obtenemos un vector de temperaturas que se distribuirán en el espacio de estudio de tal forma que podremos obtener una distribución de las mismas y con ello extraer una función de densidad que nos proporcione información de cómo se reparten los distintos posibles escenarios y cómo de probable es que se

dé cada uno de ellos. Esto lo podemos observar en la Figura 8, en las lineas de color azul claro, se ha realizado una partición de un intervalo de temperaturas, iniciales centrada en el valor medido, y se observa que para cada una de ellas el modelo nos proporciona valores futuros de la temperatura repartidos. En el eje ortogonal al plano donde reside la temperatura y el alcance podemos observar cómo se distribuyen los distintaos valores, dibujándose la función de densidad más alta para aquellos valores que se dan con mayor frecuencia.

Una vez llegados a este punto nos es muy sencillo realizar un estudio de la incertidumbre de nuestras predicciones con un determinado modelo pues podemos hacer uso de parámetros de centralización o de dispersión como pueden ser la media, la mediana, desviación típica media o varianza entre otras. Esto mejorará considerablemente nuestra fiabilidad en las predicciones pues podremos darle más atención a aquellos escenarios en los que obtengamos mayores frecuencias. Además, gracias a esto podremos también focalizar la atención a aquellas situaciones que conlleven un riego alto para la población como pueden ser lluvias intensas, vientos fuertes o cualquier situación que pueda conllevar peligro, en resumen. Dandole una buena granularidad a nuestro intervalo de temperaturas iniciales, lo más próximo a un continuo, podremos obtener un mayor abaníco de escenarios atmosféricos posibles.

Obvio es, que a pesar del gran avance que supone realizar un estudio así a la hora de cuantificar la incertidummbre y de aumentar la calidad de nuestras predicciones, no estamos exentos de errores, los modelos seguirán teniendo errores tanto en los valores que les damos a sus parámetros como en los valores iniciales de las variables que depende pues nuestros aparatos de medida seguirán proporcionándonos errores. La ventaja de la que disponemos ahora es que este sistema de predicción nos garantiza una mayor **predecibilidad**.

Volvamos al ejemplo del huerto. Una vez obtenida una distribución de frecuencias (para un continuo sería nuestra distribución de probabilidad) definamos la media y observemos lo que ocurre,

$$\boxed{\overline{x} = \int_I x\rho(x)dx} \tag{5}$$

$$\boxed{\overline{x} = \frac{1}{\sqrt{N}}\sum_i^N x_i} \tag{6}$$

donde (5) es para el caso continuo y (6) para el caso discreto.

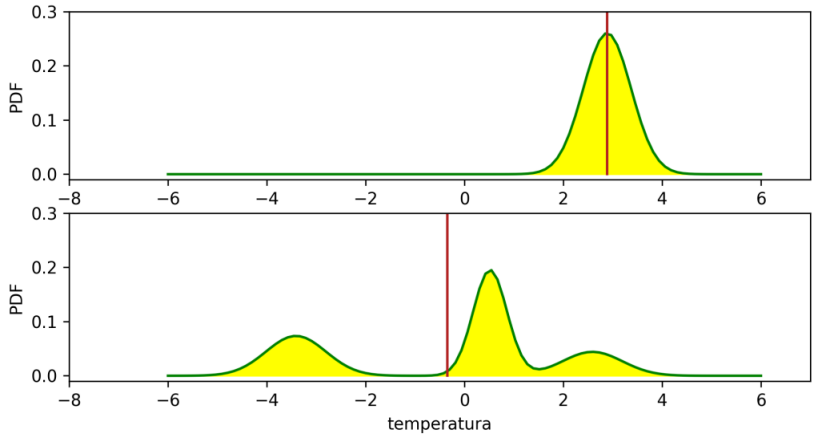

Figura 9: Se representan dos distribuciones de densidad continuas donde la linea roja representa el valor medio. La gráfica inferior es la que se discute en nuestro modelo para el huerto.

Podemos observar en la Figura 9 el valor medio de la muestra que obtenemos en el caso citado. Vemos que esta cae en un valor de temperatura que en principio tiene una probabilidad casi nula, si es que no lo es.

A la hora de realizar una predicción hay que tener cuidado pues como observamos, su valor generalmente no tiene porqué encontrarse en el espacio de estados factibles, es decir, puede que no exista ningún escenario en el que se dé el valor de la media. Para distribuciones muy simétricas la media, probablemente, tome valores dentro de los factibles pues ésta será cercana a la mediana mientras, como podemos intuir con la Figura 9, a medida que nos vayamos encontrando con distribuciones más asimétricas tendremos una mayor discrepancia entre la media y la mediana.

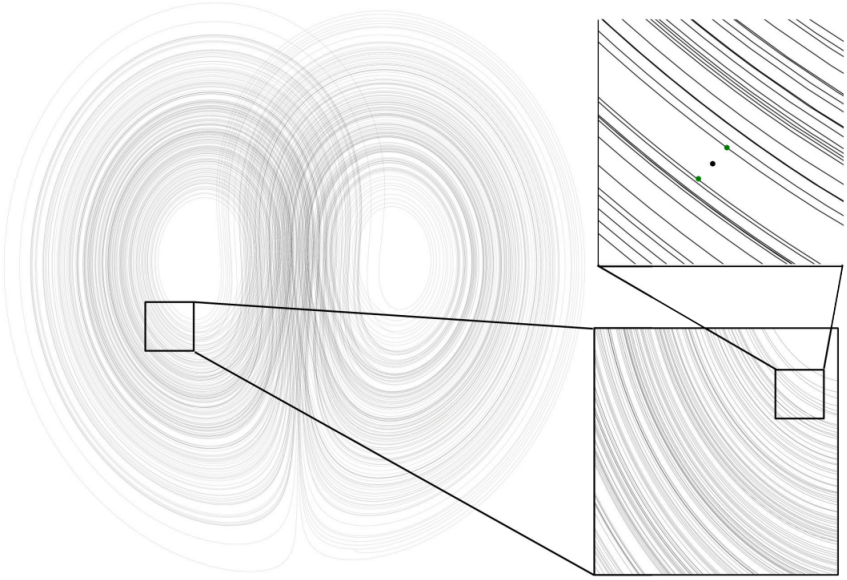

Figura 10: Se representa en un punto negro el valor medio de dos estados atmosféricos factibles en el atractor de Lorenz.

De nuevo, en la Figura 10 podemos observar lo que acabamos de decir. El valor medio de todos los escenarios obtenidos por nuestros modelos no tiene porqué caer en uno de ellos, no tiene porqué vivir en el espacio de estados atmosféricos que nos determinan la distribución de frecuencias.

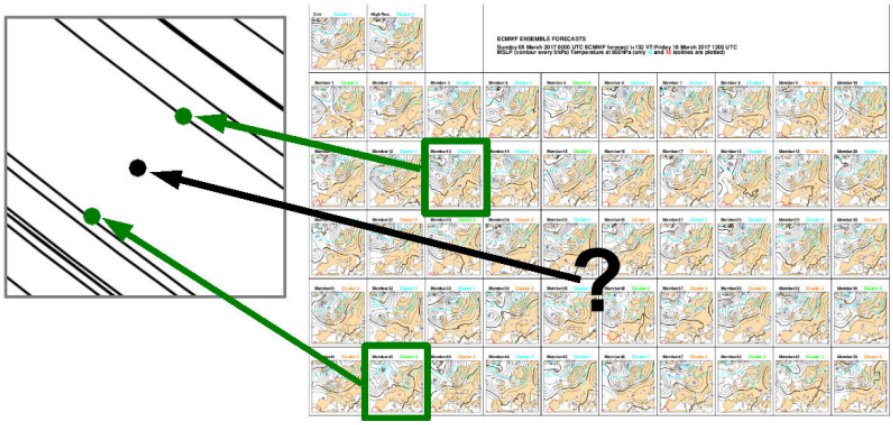

A pesar de todo esto, la media es un parámetro de centralización de enorme calidad determinista, es decir, a pesar del problema que presenta, la discrepancia que obtenemos de un escenario con dichos valores medios, es menor de la que obtendriamos al lanzar un modelo determinista en solitario. No obstante, el objetivo de construir un sistema de predicción por conjuntos no es utilizar la media como predictor.

En cuanto a la dispersión de nuestro espacio de estados, tenemos como parámetro útil la varianza o la desviación estandar,

$$\boxed{\overline{\sigma}^2 = \frac{1}{\sqrt{N-1}} \sum_{i}^{N} (x_i - \overline{x})^2} \tag{7}$$

$$\boxed{\overline{\sigma}^2 = \int_I (x_i - \overline{x})^2 \rho(x) dx} \tag{8}$$

de nuevo, la ecuación (7) es para el caso discreto y la (8) para el caso continuo.

Este parámetro nos proporciona una visión del espacio de probabilidades bastante amplia pues de él podemos extraer información varia. Por ejemplo, si obtenemos una baja dispersión, sabremos que tenemos escenarios muy cercanos a un valor medio, una distribución, más o menos, simétrica. Normalmente esta última se da cuando tenemos una atmósfera estable, en condiciones anticiclónicas. Mientras que si tenemos una gran dispersión, querrá decir que al correr diversas veces el modelo hemos obtenido una gran variedad de escenarios, en principio inconsistentes entre ellos. En este último caso nos será más complicado dar una predicción pues tendremos una baja predictibilidad.

En una distribución con una gran varianza será más viable que tengamos valores atípicos. Estos pueden ser debidos a errores y de forma general se pueden descartar. Sin embargo, antes de descartarlos hay que prestarles atención pues pueden ser valores asociados a escenarios adversos o extremos.

Una forma de desechar estos escenarios atípicos es hacer uso del rango intercuartílico, escual consiste simplemente en quedarnos con aquellos escenarios que caigan por encima del cuartil veinticinco y por debajo del setenta y cinco.

El tema da para mucho más, sin embargo, no queremos alargarnos mucho más con esto. Antes de concluir queremos hacer mención de algunos métodos que se utilizan como alternativa de los SPC. Antes de asentar los fundamentos matemáticos sobre los que descansan los SPC se hacia uso de ellos.

5.1. Consistencia entre pasadas

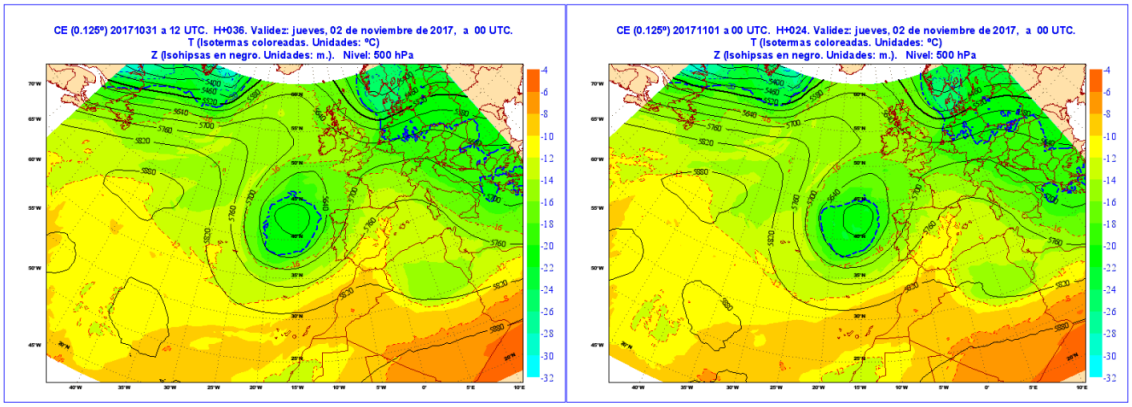

Figura 11: Dos pasadas consistentes del mismo modelo válidas para un mismo instante futuro: jueves 2 de noviembre de 2017 a las 00 UTC). Se muestran los campos de altura geopotencial y temperatura en 500 hPa. AEMET 2017

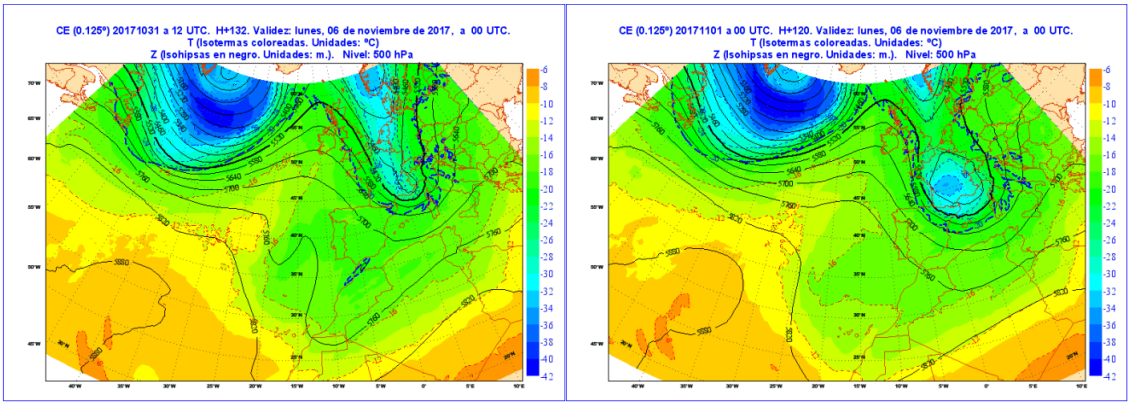

Figura 12: Dos pasadas, esta vez inconsistentes, del mismo modelo válidas para un mismo instante futuro: lunes 6 de noviembre de 2017 a las 00 UTC).

Este método consiste basicamente en correr un mismo modelo, con diferentes datos de partida, para un mismo instante futuro. Este se basa en un punto de vista más subjetivo que los SPC pues ya depende de la persona encargada la interpretación. Debe de ser él el que cuantifique de alguna manera la calidad de los resultados y lo consistente o no que pueden llegar a ser, ya que en este caso no se disponen de parámetros ni de centralización ni de dispersión con los que poder hacer un estudio de la incertidumbre.

5.2. Consistencia entre modelos

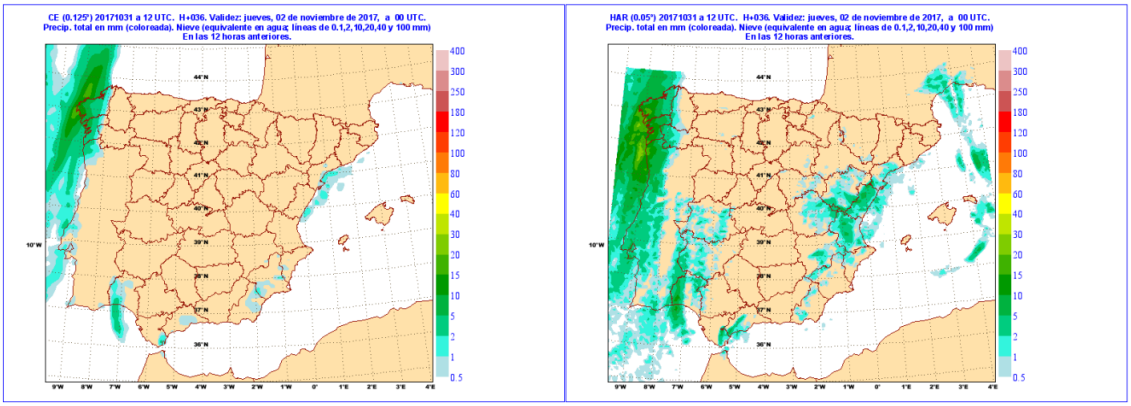

Figura 13: : Campos de precipitación acumulada de dos modelos, inconsistentes, válidos para un mismo instante futuro: jueves 2 de noviembre de 2017 a las 00 UTC). A la izquierda ECHRES y, a la derecha, HARMONIE-AROME que muestra señal consistente en Galicia pero presenta patrones en otras regiones que no ve ECHRES. AEMET 2017

La forma de proceder es muy similar a la comentada anteriormente. En este caso se hace uso de diferentes modelos y se comparan entre sí. Esto algo de gran utilidad, pues no todos los modelos se comportan igual en las mismas situaciones, incluso un determinado modelo puede mostrar discrepancias considerables ante situaciones de gran parecido entre sí. Es por ello, que realizar un análisis haciendo uso de una variedad de distintos modelos nos puede ayudar a tener una mayor predecibilidad antes los escenarios que se pueden dar. Claro es, que al igual que en el método anterior, todo queda al estudio de la persona que tenga que interpretar los resultados, es su deber realizar un análisis de los mismos. Tendrá que tener en cuenta factores como la resolución del modelo, si estos tienen en cuenta la orografía en mayor o menor medida (importante en la predicción de la precipitación), etc.

Referencias

[1] Santos Burguete, Carlos.(2018). Física del caos en la predicción meteorológica. Agencia Estatal de Meteorología. http://www.aemet.es/es/conocermas/recursos_en_linea/publicaciones_y_estudios/publicaciones/detalles/Fisica_del_caos_en_la_predicc_meteo

[2] R.Holton, James.(1990). Introducción a la meteorología dinámica. Ed. Instituto nacional de meteorología.