

JUAN MANUEL RUIZ MUÑOZ

Petrer, Alicante, España ♦ +34 678 23 12 12 ♦ juanmanuelruiz383@gmail.com ♦ GitHub ♦ LinkedIn ♦ Sitio Web

PERFIL

ML Engineer con formación en Física y Matemáticas y alrededor de dos años de experiencia llevando modelos de **Computer Vision** y **LLMs** de la investigación a producción. Especializado en pipelines de detección y segmentación de defectos industriales y en **fine-tuning** de modelos de lenguaje (LoRA, RAG, OCR multimodal), con despliegue real mediante Docker, vLLM y AWS. Mi base científica me da rigor para entender los modelos a fondo y resolver problemas no triviales. Autor de una publicación en DCAI'25 sobre arquitecturas basadas en LLMs.

EXPERIENCIA PROFESIONAL

Vraia Corp.

06/2025 – Presente

ML Engineer · Computer Vision & LLMs

Elche, Alicante, España

- Diseño y entrenamiento de modelos de detección y segmentación de defectos (CNNs, Vision Transformers, YOLO, RF-DETR) para inspección industrial de neumáticos, alcanzando **mAP@50:95 de 0,83** en segmentación multiclase sobre datasets propios de miles de imágenes.
- Fine-tuning de un modelo de lenguaje multimodal (GLM-OCR) con **LoRA** vía LLaMA-Factory para extracción de texto en flancos de neumático, logrando **98,56% de exact match** en producción; serving con vLLM y Ollama.
- Desarrollo de un pipeline de **generación sintética de defectos** mediante modelos generativos para ampliar datasets escasos y mejorar la robustez de la detección.
- Construcción de pipelines **ETL** para extracción, transformación y aumento de datasets visuales a escala industrial.
- Despliegue y monitorización de modelos con **Docker, MLflow y TensorBoard**, y definición de métricas de evaluación (Precision, Recall, F1, mAP, IoU) para validación en tiempo real.
- Documentación técnica de arquitecturas y pipelines, y especificación algorítmica en C++ para su integración por el equipo cliente.

AIR Institute & Grupo de investigación BISITE

06/2024 – 06/2025

Data Scientist & AI Researcher

Salamanca, Castilla y León, España

- Investigación y desarrollo de soluciones de **NLP y LLMs**, incluyendo una arquitectura de detección de desinformación basada en ontologías generadas con modelos de lenguaje (publicada en DCAI'25).
- Implementación de pipelines **RAG** y de recuperación semántica con bases de datos vectoriales (ChromaDB) y sistemas multi-agente (Ollama, DeepSeek, GPT-4o-mini), con foco en reducir coste y latencia.
- Proyectos de Computer Vision (detección, clasificación y segmentación) y gestión del ciclo completo de proyectos ML: requisitos, desarrollo, validación y documentación.
- Interacción directa con clientes para captura de requisitos y adaptación de soluciones state-of-the-art a casos de uso reales.

Universidad Miguel Hernández — Grupo SCOLab

01/2024 – 07/2024

Investigador · Contrato de prácticas

Elche, Alicante, España

- Desarrollo de métodos Lagrangianos para la identificación automática de situaciones de bloqueo atmosférico (base del TFG y de una publicación en desarrollo).
- Colaboración en proyectos del grupo de física atmosférica.

EDUCACIÓN

Universidad de Alicante

Grado en Física

Sant Vicent del Raspeig, Alicante, España

2020 – 2024

- TFG: *Un método Lagrangiano para la identificación de situaciones de bloqueo atmosférico*.
- Durante estos años combiné los estudios con asignaturas del Grado en Matemáticas (+120 ECTS), en el programa de estudios simultáneos de la Universidad de Alicante.

Universidad de Salamanca

Beca de movilidad SICUE — Física y Matemáticas

Salamanca, Castilla y León, España

2022 – 2023

PUBLICACIONES

- **DCAI'25:** *AI-Powered Ontology-Based Architecture for Misinformation Detection in Fiction Works*. [PDF]
- *En desarrollo:* A Lagrangian Method for the Identification of Atmospheric Blocking Situations.

COMPETENCIAS TÉCNICAS

LLMs & NLP	Fine-tuning (LoRA), LLaMA-Factory, RAG, Transformers, vLLM, Ollama, embeddings y búsqueda semántica, bases de datos vectoriales (ChromaDB, FAISS), prompt engineering
Computer Vision	PyTorch, TensorFlow, Keras, OpenCV, CNNs, Vision Transformers, YOLO, RF-DETR, modelos de difusión (FLUX.1), detección y segmentación
Lenguajes y análisis	Python (NumPy, Pandas, scikit-learn, Matplotlib), C++ (lectura y especificación), R, análisis estadístico, LaTeX
MLOps y herramientas	Docker, MLflow, TensorBoard, Git & GitHub, AWS (Cloud Technical Essentials), Linux/SSH, uv, Cursor, VSCode, Jupyter
Idiomas	Español (nativo) · Inglés (B1; escrito fluido, en mejora para conversación técnica)

CERTIFICADOS

- AWS Cloud Technical Essentials
- Build Basic Generative Adversarial Networks (GANs)
- Introduction to Front-End Development
- Cambridge English — Council of Europe Level B1 (Preliminary)

VOLUNTARIADO

- Tareas de divulgación en la Nit de la Investigació 2023 (Universidad de Alicante).