PREDICTIBILIDAD ATMOSFÉRICA

Ruiz Muñoz, Juan Manuel
Sánchez Granados, María
Vázquez de Luis, Alicia

Mayo 2023

Resumen

La predecibilidad es a la predicción como el romance es al sexo.

Índice

1. Introducción **3**

2. Teoría del caos. Sistemas atmosféricos **3**

2.1. El atractor de Lorenz 4

2.2. Conclusiones teoría del caos 5

3. Modelos atmosféricos **6**

3.1. Escalas y anidamiento 6

3.2. Componentes de un modelo atmosférico 7

3.2.1. Asimilación de datos 7

3.2.2. Dinámica 7

3.2.3. Parametrizaciones físicas 8

4. Predecibilidad **9**

5. Sistemas de predicción por conjuntos, SPC **10**

5.1. Consistencia entre pasadas 18

5.2. Consistencia entre modelos 19

Referencias **20**

1. Introducción

A lo largo de la historia la predicción meteorológica ha tomado una gran repercusión en la vida de las personas por su influencia en las cosechas, en los transportes o en la planificación de eventos. Por eso las personas siempre han exigido a los meteorólogos una exactitud muy grande en sus previsiones, sin saber que este hecho es prácticamente imposible debido al carácter caótico de la atmósfera.

Hace algunas décadas el meteorólogo Edward Lorenz trató de darle una explicación a todo este fenómeno, desarrollando la teoría del caos que explicaremos más adelante. Para dar una introducción a éste tema tendremos que introducir los términos de *precisión* y *exactitud*, refiriéndose el primero a predicciones muy concretas en el tiempo y el espacio mientras que el segundo mide si la predicción acierta o no. Con estos dos términos ya introducidos podemos decir que la teoría del caos a grandes rasgos implica que no vamos a poder hacer predicciones cada vez más precisas y exactas, también nos quiere decir que la atmósfera es muy sensible a pequeñas variaciones en las condiciones iniciales.

Para solucionar este problema, se han desarrollado modelos numéricos sobre el comportamiento de la atmósfera, los cuales explicaremos más adelante.

2. Teoría del caos. Sistemas atmosféricos

La física del caos es un campo que se ocupa del estudio de sistemas dinámicos complejos y caóticos. Estos sistemas son aquellos que son altamente sensibles a las condiciones iniciales y cuyas trayectorias en el tiempo parecen ser aleatorias e impredecibles, aunque suelen seguir ciertas leyes deterministas.

El estudio de la física del caos se originó en la década de 1960 a partir del trabajo de científicos como Edward Lorenz, que descubrieron que pequeñas perturbaciones en las condiciones iniciales de un sistema dinámico pueden llevar a grandes cambios en su comportamiento.

Con nuestro interés de describir la dinámica de la atmósfera con el fin de poder predecir los fenómenos que van a ocurrir en ella, nos vamos a centrar en el estudio de sistemas dinámicos. Éstos describen sistemas cuyo estado varía con el tiempo. En función de las propiedades del sistema dinámico distinguiremos los:

1. Sistemas dinámicos discretos: Su evolución puede describirse dando pequeños saltos en el tiempo, en matemáticas y programación se representan mediante ecuaciones de recursividad.
$$x_{k+1} = f(x_k)$$
2. Sistemas dinámicos continuos: Se puede caracterizar mediante la evolución en el tiempo de forma continua, para estudiarlos matemáticamente utilizamos ecuaciones diferenciales:
$$\frac{dx}{dt} = f(x)$$

También podemos clasificar los sitemas dinámicos en:

1. Sistemas dinámicos lineales: En este tipo de sistemas dinámicos, se cumple el principio de superposición para sus soluciones, lo más importante es que tiene solución analítica.

2. Sistemas dinámicos no lineales: En este otro tipo de sistemas dinámicos no se puede aplicar el principio de superposición a las soluciones y además no tenemos solución analítica y por tanto tendremos que buscar métodos de resolución numérica para modelarlo. Si estos sistemas muestran el mezclado topológico entonces tendremos un *sistema caótico*.

Paradigma clásico	**Paradigma del caos**
Sistemas dinámicos lineales	Sistemas dinámicos no lineales
Ecuaciones diferenciales lineales	Ecuaciones diferenciales no lineales
Sensibilidad acotada a las condiciones iniciales	Sensibilidad a las condiciones iniciales
Solución analítica	No existe solución analítica
El futuro de un sistema dinámico se puede calcular y predecir a partir del conocimiento de su estado anterior	El futuro de un sistema dinámico se puede calcular pero en general es impredecible a partir de un cierto horizonte: predecibilidad limitada en el tiempo
Determinismo	Determinismo formal, pero limitaciones en la predecibilidad
El comportamiento del todo se puede inferir como la suma de los comportamientos de las partes	La suma de las partes introduce comportamientos cualitativamente nuevos, emergen nuevas propiedades
Dualidad conceptual *orden* vs *caos*	Se profundiza y enriquece el concepto de *caos*: no es opuesto al orden, sino un distinto tipo o grado de orden.

Figura 1: Tabla comparativa entre los paradigmas clásicos y del caos de la referencia [la referencia]

2.1. El atractor de Lorenz

En 1923 Edward Lorenz investigó los límites de la predicción meteológica, para ello ideó un sistema dinámico no lineal determinante. Considerando la atmósfera como un sistema cerrado, limitado por el espacio y por la superficie terrestre. El modelo de Lorenz consta de un sistema como este, un sistema cerrado tridimensional, por lo que aporta una gran información sobre el sistema atmosférico.

Al ser un sistema dinámico y no lineal no tiene una solución analítica, con lo que no podemos saber el valor de las variables en función del tiempo a partir de una sola expresión cerrada, sino que solo lo podremos resolver numéricamente.

Cuando representamos la evolución de este sistema obtenemos la famosa figura que recuerda a las alas de una mariposa:

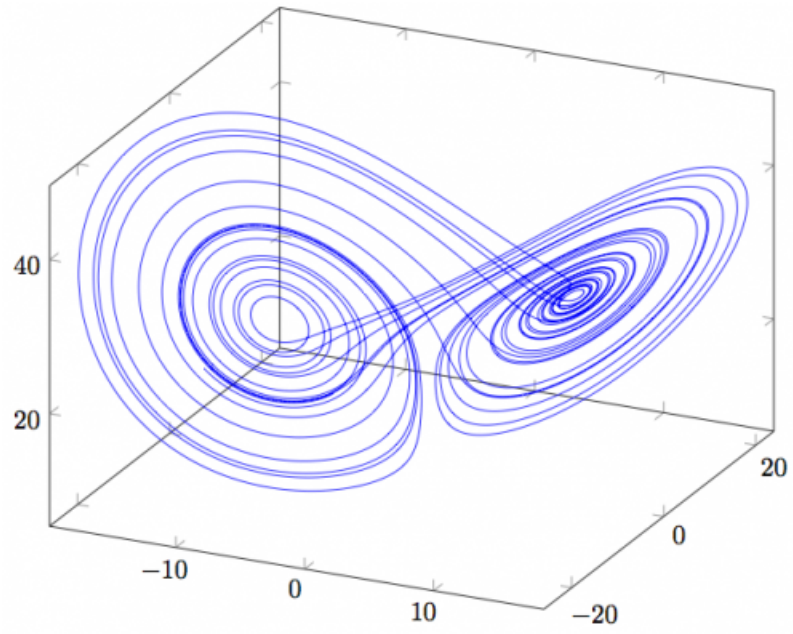

Figura 2: Representación del sistema de Lorenz: Atractor de Lorenz

En la figura podemos ver como hay zonas que tienen preferencia sobre otras y que las líneas se agrupan en torno a dichas zonas. También observamos que las lineas no se cortan nunca.

2.2. Conclusiones teoría del caos

El atractor de Lorenz es un sistema dinámico no lineal, es decir, es sensible a las condiciones iniciales. Por lo tanto, pequeñas condiciones iniciales pueden conducir a grandes diferencias en la evolución del sistema, esto limita la *predecibilidad*, lo cuál desarrollaremos más adelante.

La atmósfera es un sistema altamente no lineal y caótico, por tanto tiene una precedibilidad en un tiempo finito. Mediante los modelos que vamos a explicar a continuación se ha estudiado que la fiabilidad de las predicciones es de como mucho 10 días. En nuestro día a día podemos experimentar la dificultad de que las predicciones sean correctas.

3. Modelos atmosféricos

El fin principal de la meteorología dinámica es predecir el estado futuro de la atmósfera a partir de un estado inicial, un sistema de ecuaciones de prediccion y un método de integración de las ecuaciones en el tiempo. Esto puede conseguirse mediante la elaboración de modelos atmosféricos de Predicción Numérica del Tiempo (PNT).

3.1. Escalas y anidamiento

Para elaborar un modelo lo primero que tiene que tenerse en cuenta es la escala a la que se va a usar, tanto espacial como temporal.

La porción de espacio físico que cubre el modelo se le llama dominio. Este dominio se dividirá en celdas de malla, es decir, subdivisiones horizontales que lo separan en porciones. La resolución horizontal del modelo será el lado de una celda (por ejemplo 10Km). También puede haber subdivisiones verticales que reciben el nombre de niveles verticales del modelo (no suelen ser equiespaciados debido a que la densidad no desciende de manera lineal a medida que ascendemos en la atmósfera).

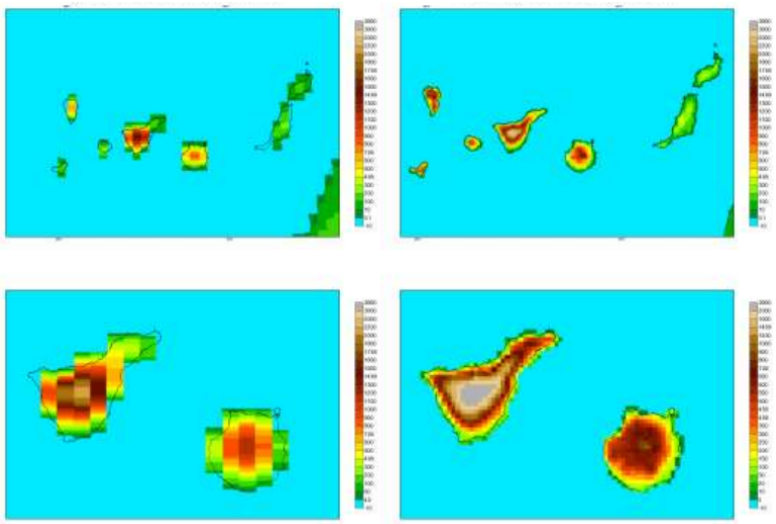

Figura 3: Comparación entre la resolución de dos modelos, a la izquierda el modelo global ECHRES (resolución horizontal: 16Km) y a la derecha el modelo regional de mesoescala HARMONIE-AROME (resolución horizontal: 2.5Km)

En cuanto al tiempo, tomamos como punto de incio la fecha y hora de las observaciones, este instante se denomina la pasada del modelo y el tiempo simulado es el recorrido o rango. Los modelos globales que simulan la atmósfera de todo el planeta requieren observaciones globales y pueden llegar hasta 9Km de resolución horizontal del ECHRES, un modelo usado por el Centro Europeo de Predicción a Plazo Medio. Los modelos regionales o de área limitada pueden ser más sofisticados y por tanto obtener mayor resolución horizontal, en torno a 2Km. Los modelos regionales necesitan de un modelo global que les proporcione datos inciales y de contorno, se dice entonces que el modelo regional está anidado en el global. De la misma manera pueden anidarse un modelo regional a otro de mayor escala.

3.2. Componentes de un modelo atmosférico

3.2.1. Asimilación de datos

El primer paso es obtener datos mediante las observaciones en distintos niveles de la atmósfera. A pesar de que se realizan multitud de observaciones mediante distintos métodos y que estas son compartidas casi a tiempo real mediante el sistema mundial de telecomunicaciones para que distintos centros puedan utilizarlas, pueden no ser suficientes debido a que los modelos discretizan la atmósfera en pequeños elementos y se tendría que conocer todas las variables. Este problema puede resolverse utilizando el método de predicción previa o campo previo. Por tanto la asimilación de datos se resume en aunar observaciones y predicciones de corto plazo que conformarán las condiciones iniciales el modelo.

Figura 4: Sistema Global de Observación

3.2.2. Dinámica

Partimos de las ecuaciones de Euler, que son las simplificaciones de las ecuaciones de Navier-Stokes al despreciar los efectos de la viscosidad y la conductividad térmica. Este sistema de ecuaciones se vuelve a simplificar aun más utilizando la aproximación hidrostática y el resultado es el más utilizado por los modelos globales, reciben el nombre de ecuaciones primitivas

1. Conservación del momento

$$\frac{dv_h}{dt} = -fk \times v_h - \frac{RT}{p}\nabla p \tag{1}$$

2. Conservación de la energía

$$\frac{dT}{dt} = \frac{RT}{C_p p}\frac{dp}{dt} \tag{2}$$

3. Conservación de la masa

$$\frac{dp}{dt} = \frac{p}{1-\frac{R}{C_p}}\left(\nabla \cdot v_h + \frac{\partial w}{\partial z}\right) \tag{3}$$

4. Ecuación hidrostática

$$\frac{\partial p}{\partial z} = \frac{p}{RT} g \tag{4}$$

Para resolver estas ecuaciones se pueden usar distintas geometrías y opciones para discretizar espacial y temporalmente la atmósfera, la mayoría de modelos optan por aproximar la atmósfera en volúmenes tridimensionales, desarrollemos un poco los métodos empleados:

Método de diferencias finitas o leap frog: Se utiliza para discretizar espacial y temporalmente las ecuaciones atmosféricas. Realiza estimaciones de las derivadas parciales de una función en un punto a partir de los valores de la función en los puntos adyacentes.

$$\frac{\partial f}{\partial x} = \frac{f(x + \Delta x) - f(x - \Delta x)}{2\Delta x}$$

Siendo Δx el tamaño de la celda de malla.

Método espectral: Expresa las variables como una combinación lineal de una serie de funciones elegidas para facilitar la solución, estas suelen ser armónicos esféricos $Y_{m,n}(\lambda, \mu)$, así que cualquier variables puede expresarse:

$$f(\lambda, \mu, t) = \sum_{m,n} a_{m,n} Y_{m,n}(\lambda, \mu)$$

El número de funciones que se escojan definirá la truncación del modelo, la mayoría de modelos globales utilizan este método y algunos regionales. En principio este método es más preciso que el de diferencias finitas pero requiere de mucho más tiempo de cálculo.

Método de elementos finitos: Con este modelo podemos establecer que las funciones solo sean no nulas en un dominio local, es menos preciso que el espectral pero al poder centrarse en un dominio limitado tiene mayor eficiencia. Además permite rejillas no regulares de manera que podemos aumentar la resolución en un área de interés.

Modelos no hidrostáticos: Si aumentamos mucho la resolución espacial llega un momento en el que la hipótesis hidrostática deja de ser válida y se deben incluir ecuaciones adicional y considerar procesos microfísicos de formación de nubes más complejos. El modelo HARMONIE-AROME es de este tipo.

3.2.3. Parametrizaciones físicas

Hay procesos que deben parametrizarse porque tienen lugar a escala demasiado pequeña para el modelo, lo que interesa es conocer de forma aproximada los efectos que tienen estos procesos sobre las variables de pronóstico. Lo que se hace normalmente es calcular estos procesos para columnas independientes de la atmósfera y luego incluir las tendencias en la predicción. También se incluyen los efectos de la humedad usando las humedades específicas para el vapor de agua, agua líquida, hielo, lluvia y nieve r_v, r_l, r_i, r_R, r_S. Hablaremos un poco sobre estos procesos

Radiación: Se trata de estimar los flujos radiativos en los distintos niveles del modelo, para ello muchos modelos ya incluyen el ozono y los aerosoles como variables de pronóstico y el cálculo de los flujos se reparten en los intervalos de absorción y dispersión más importantes. Aunque se trate de estimaciones el error suele ser pequeño para aire claro, si hay nubes requieren una modelización más sofisticada.

Procesos orográficos: La orografía tenida en cuenta en el modelo depende lógicamente de su resolución horizontal, por ello se parametrizan bloqueos de flujo atmosférico por obstáculos y turbulencia de pequeña escala generada por las irregularidades del terreno.

Procesos superficiales: Tiene en cuenta la temperatura y humedad en el suelo para distintos tipos de suelo y vegetación, se utilizan esquemas de tipo mosaico donde encontramos distintos tipos de superficie por ejemplo urbana, mar y natural con vegetación.

Turbulencia: La capa límite planetaria está muy influenciada por la superficie terrestre por los flujos de calor y humedad que le llegan de esta, estos intercambios dan lugar a remolinos turbulentos. Durante la noche la atmósfera se estabiliza pero durante el día estos remolinos modifican las condiciones alrededor en unos cientos de metros. Se cometen mayores errores con atmósfera estable y por ellos es muy difícil la simulación de nieblas.

Nubes: es uno de los fenómenos que más condicionan la predecibilidad de la atmósfera y uno de los más difíciles de predecir. Se dividen en nubes estratiformes y en nubes convectivas. Las primeras son grades sistemas nubosos que ocurren a escalas superiores a la resolución del modelo y las segundas se producen porque la atmósfera es inestable en la vertical de modo que se generan corrientes verticales que pueden producir grandes precipitaciones en poco tiempo. Los modelos que parametrizan la convección utilizan esquemas de flujo de masa que representan las corrientes ascendentes y descendentes.

4. Predecibilidad

Veamos ahora los límites de estos modelos, sabemos que la atmósfera es un sistema dinámico no lineal y muy sensible a las condiciones inciales y a los parámetros del modelo, el problema de la predecibilidad consiste en que solo podemos predecir su comportamiento futuro hasta cierto punto.

Podemos interpretar que en la mariposa del atractor de Lorentz cada punto simboliza el conjunto de todos los estados en los que están cada celda de malla, es decir, si el estado de una celda de malla puede describirse mediante presión, tempertaura, humedad específica, componente zonal y componente meridional del viento, escrito como $x = (P, T, q, u, v)$, un punto de la mariposa sería $X = (x_1, x_2, ..., x_N)$ también llamado vector del espacio de estados atmosféricos. El conjunto de todos los posibles valores de X es el espacio de estado atmosféricos, es decir, la mariposa completa.

El análisis de un sistema caótico complejo como la atmósfera solo se puede hacer si lo simplificamos, asegurar una predicción acertada, es decir, la predecibilidad de sus variables, depende de las escalas temporales y espaciales y de las variables en sí. No es igual un ambiente estable que inestable, por ejemplo es muy difícil predecir inestabilidad baroclínica en escala sinóptica o convección profunda en la mesoescala.

Rápidamente nos damos cuenta de que necesitamos de un modelo probabilista para mejorar la predicción en el tiempo, puesto que un modelo determinista siempre está sujeto a errores e incertidumbres, esto es lo que ha llevado al desarrollo de sistemas de predicción por conjuntos, que proporcionan predicciones probabilistas y complementan los modelos deterministas. Además estos sistemas son capaces hoy en día de predecir la predecibilidad, es decir, pueden predecir el riesgo meteorológico y climático.

5. Sistemas de predicción por conjuntos, SPC

De los modelos de predicción deterministas obtenemos, para cada punto del espacio de estudio, un único valor. Es decir, al introducir los datos medidos (condiciones iniciales con las que iniciamos las simulación) , como pueden ser la temperatura y presión entre otras, estos nos dan como resultado un único estado atmosférico.

En un principio podemos pensar que estos modelos son muy potentes, que lo son, pues nos dan un **único** estado atmosférico futuro a partir de unas condiciones iniciales presentes (o pasadas). Ahora podemos preguntarnos, y comprobar empíricamente, que si esto es así **¿Por qué en múltiples ocasiones en la previsión de tiempo han dado lluvia y luego no ha llegado a llover?** ¿Si estos modelos solo nos dan cómo solución un único escenario porqué, a veces, se dan otros?.

Esto tiene una 'sencilla' respuesta, y es que como ya hemos comentado, los modelos utilizados no están exentos de errores. Este error nos va a depender tanto de los errores en las condiciones iniciales como de los errores en los parámetros del modelo. Al ser las ecuaciones a modelizar no lineales, estos errores se van propagando con el paso del tiempo en la simulación siendo este mayor a medida que el tiempo avanza. Es tal que a la hora de realizar una predicción son las más cercanas en el tiempo las que más fiabilidad tienen y a medida que avanza en el tiempo, aumenta la incertidumbre y por ende, es más sencillo equivocarse en la predicción.

Veamos un ejemplo en otro campo diferente de la meteorología, la dinámica de poblaciones. Aún no siendo el tema a tratar, nos parece intesante hacer un inciso en el tema ya que al tratarse de ecuaciones no lineales encontramos escenarios en los que tenemos caos.

Hemos elaborado un pqueño script de python en el que hemos definido un función en la que mostramos cómo evoluciona una población dados dos parámetros iniciales. Por un lado, tenemos x_0 el cual denota la población inicial del 0 al 1, donde, si por ejemplo, $x_0 = 0{,}5$ quiere decir que la población se encuentra al 50 % de su máximo. Por otro lado, tenemos el parámetro r que nos ayudará a darle un valor número al ritmo de reproducción de la población,

$$X_n = rX_0\left(1 - X_0\right).$$

Este modelo es interesante ya que tenemos dos regímenes de estudio puesto que existen valores de r para los cuáles la evolución del sistema se vuelve caótica y dejamos de tener convergencia para un t infinito. El sistema oscilará entre dos valores.

```python
def poblacion(r, x_0, cota):

    evolucion = [x_0]

    x_p = r*x_0*(1-x_0)

    evolucion.append(x_p)

    while (abs(evolucion[len(evolucion)-1] - evolucion[len(evolucion)-2])> cota):

        x = evolucion[len(evolucion) - 1]*r*(1-evolucion[len(evolucion)-1])
        evolucion.append(x)

        if len(evolucion)>500: break


    return print(f'El valor de estabilización es {evolucion[len(evolucion) - 1]}'), len(evolucion), evolucion
```

Figura 2: Función población definida en Python.

En la función que se muestra en la Figura 2 (*poblacion*) se realiza una relación de recursividad entre la población n y otra $n+1$, lo que se puede traducir cómo que calculamos una población futura a partir de una anterior o presente. La función nos devuelve un vector, *evolucion*, con los valores de X_n siempre que se hayan dado las condiciones que se imponen en la función, la de convergencia, o bien que el vector supere un cierto número de elementos (que será nuestro corte cuando el sistema no converja).

```
estabilizador1, iteraciones1, evolucion1 = poblacion(1.5, 0.5 ,10**-31)
estabilizador2, iteraciones2, evolucion2 = poblacion(1, 0.5 ,10**-31)
```

Figura 3: Valores de r para dos poblaciones en régimen no caótico.

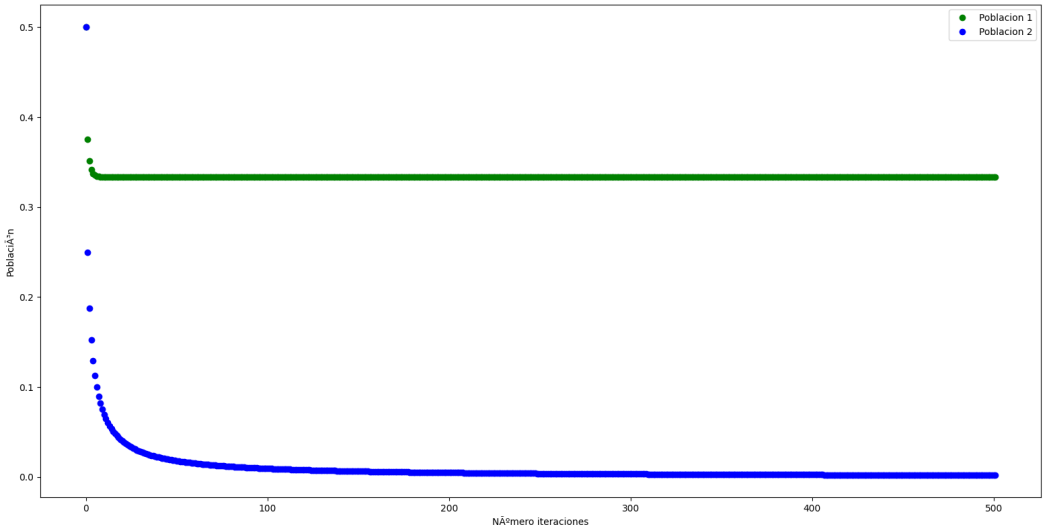

Figura 4: Población en función del tiempo (n) en régimen no caótico. Se observa que ambas poblaciones convergen a un valor de la población dados, para tiempos lo suficientemente grandes.

```
estabilizador1, iteraciones1, evolucion1 = poblacion(3, 0.5 ,10**-31)
estabilizador2, iteraciones2, evolucion2 = poblacion(3.005, 0.5 ,10**-31)
```

Figura 5: Valores de r para dos poblaciones en régimen caótico.

Dados ahora los valores de r que se muestran en la Figura 5 obtenemos la gráfica de la Figura 6. Dado el orden de la diferencia entre ambos valores de r para las distintas poblaciones, podemos considerar uno de ellos como una pequeña perturbación del otro.

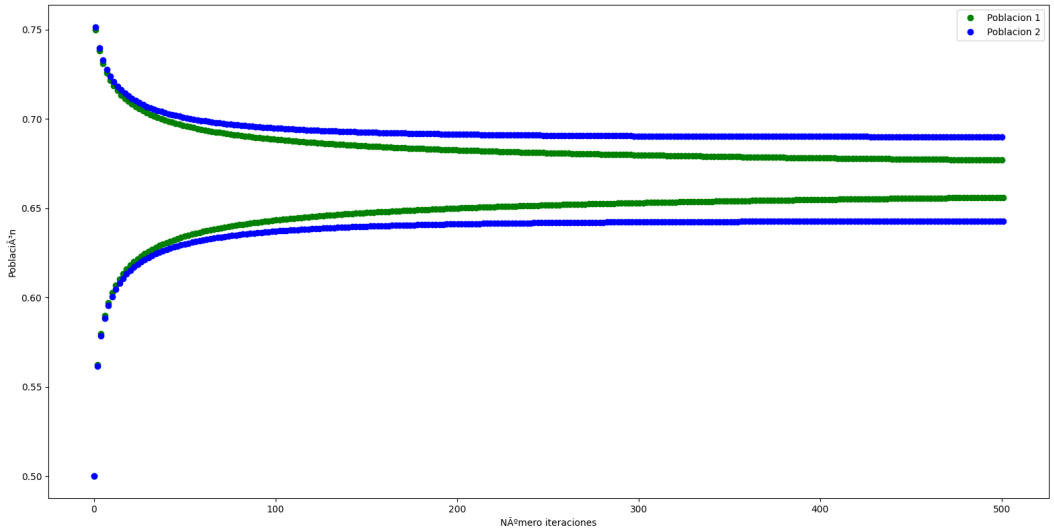

Figura 6: Población en función del tiempo (n) en régimen caótico. Se observa que ambas poblaciones no convergen para tiempos infinitos. Esto es porque las poblaciones van oscilando entre dos valores para tiempos grandes. Digamos que tenemos dos puntos de convergencia para ambas sucesiones.

Algo importante a resaltar, y uno de los principales motivos por el cuál comentamos este caso, es que la diferencia entre ambas poblaciones va incrementando a medida que avanzamos en el tiempo y además esta discrepancia se hace mayor de forma no lineal, como era de esperar.

Limitándonos a quedarnos solo con este último detalle podemos realizar una analogía con los modelos de predicción meteorológica y entender así mejor el porqué las predicciones que se realizan del tiempo van perdiendo fiabilidad a medida que nos alejamos en el tiempo.

Supongamos que la población 1, representada en la Figura 6 de color verde, es el escenario real que se da del estado atmosférico. El azul, población 2, un estado atmosférico obtenido corriendo un modelo de predicción determinista. Al igual que en el caso de la dinámica de poblaciones, las ecuaciones del modelo son no lineales con lo que pequeñas perturbaciones (errores) en los valores iniciales introducidos en el modelo nos llevará a que el sistema evolucione de forma análoga a como observamos en la Figura 6. El error introducido no será demasidado elevado para tiempos pequeños pero a medida que vayan pasando los días lo más probable es que empecemos a tener una discrepancia considerable con la realidad. Los errores se propagan de forma no lineal.

Hemos asumido que a medida que trancurre el tiempo vamos perdiendo fiabilidad en la predicción que nos proporciona un determinado modelo. Esta es más fiable para tiempos pequeños, digamos unos pocos dias. Ahora podemos preguntarnos **cómo de fiable es el estado atmosférico que nos pueda proporcionar un determinado modelo determinista**, pues a final de cuentas solo nos proporciona un único escenario. Podemos poner a prueba el modelo lanzando predicciones y en función del grado de acierto que tenga darle una mayor o menor fiabilidad, ¿no?. Lo cierto es que esto último no tiene mucho sentido pues que el modelo acierte con bastante cercania el tiempo a lo largo de una semana,

no nos garantiza que la próxima también lo vaya a hacer. Y es que no es lo mismo una atmósfera estable que una inestable, en el segundo caso tendremos mayor incertidumbre pues esteremos expuestos a mayores errores. No nos vale predecir muy bien una semana y a la siguiente no, hay en juego mucho, dinero sobretodo.

El paso de un marco determinista a uno probabilista puede ayudarnos. No dejaremos de tener error sin embargo, podremos cuantificar de cierta manera la incertidumbre. Para ello será necesario dotar a nuestro espacio de estudio una función que nos proporcione cómo se reparte la probabilidad de que un determinada variable tome un cierto valor en un punto de dicho espacio. Esto nos dará un abanico de estados atmosféricos posibles donde a cada uno le asociaremos una probabilidad.

$$\boxed{X(t_0 + t') \Longrightarrow \rho(t_0 + t')}$$

El objetivo es pasar de un único estado atmosférico $X(t_0 + t')$ a un abanico de ellos $\rho(t_0 + t')$. Para ello tendremos que tomar también un vector de valores iniciales (entorno del valor medido). Dado un valor de una determinada variable inicial, como puede ser la temperatura, correremos los modelos $n + 1$ veces , una para cada valor de temperatura, $\vec{T} = (t_0, t_1, \ldots, t_i, \ldots, t_n)$. Esto se realizará para cada una de las variables que pueda depender el modelo, no solo se realizará para la temperatura, claro está. Con todos ellos tendremos un vector local (para cada punto del espacio) $\vec{V_i} = (x_i, y_i, \ldots, z_i)$ el cuál contendrá todas las componentes i de cada una de las variables de las que depende el modelo, esto nos dará cómo resultado el estado atmosférico X_i. Corriendo el modelo para cada uno de los $\vec{V_i}$ tendremos el vector de estado atmosféricos, $\vec{X} = (X_0, X_1, \ldots, X_i, \ldots, X_n)$.

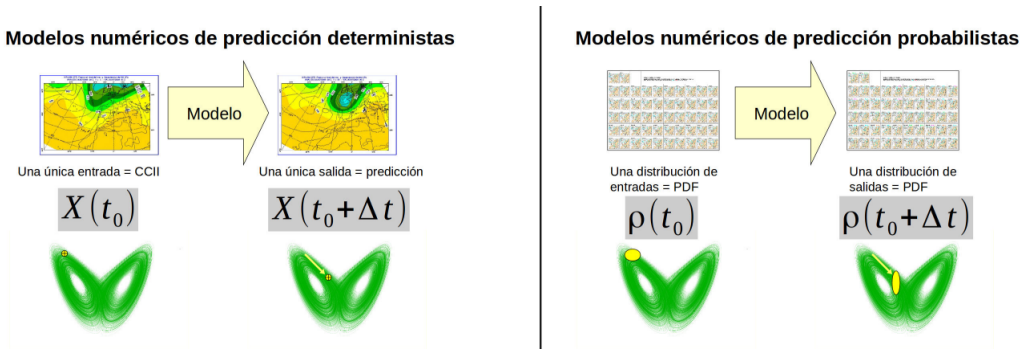

Figura 7: Paso de un esquema determinista a uno probalista. Se construye una función de densidad de probabilidad.

Entonces, dado un vector inicial, donde se concentran todos los valores iniciales para cada una de las variables independientes del modelo, si nuestro modelo depende solo de $Temperatura, Presión, Humedad = T_0, P_0, H_0$ tomaremos los vectores valores de los intervalos $[T_0 - \Delta T, T_0 + \Delta T]$, $[P_0 - \Delta P, P_0 + \Delta P]$, $[H_0 - \Delta H, H_0 + \Delta H]$. El intervalo lo partiremos en tantos valores como nosotros queramos, lo suyo sería intentar partirlo en muchos trozos, equiespaciados, para tener algo lo más parecido a un continuo. Veamos un caso en particular para explicarnos con mejor claridad.

Imaginemos que tenemos un pequeño huerto en nuestra parcela de campo y que disponemos de un sencillo modelo que nos da una predicción de la temperatura en el tiempo. Decidimos comprobar si una determinada noche las temperaturas bajaran del cero pues de ser esto así perderemos nuestra cosecha. Puesto que nuestro modelo es determinista

dado un valor de la temperatura inicial este nos devolverá un estado de la temperatura a lo largo de un intervalo de tiempo futuro, pongamos veinticuatro horas.

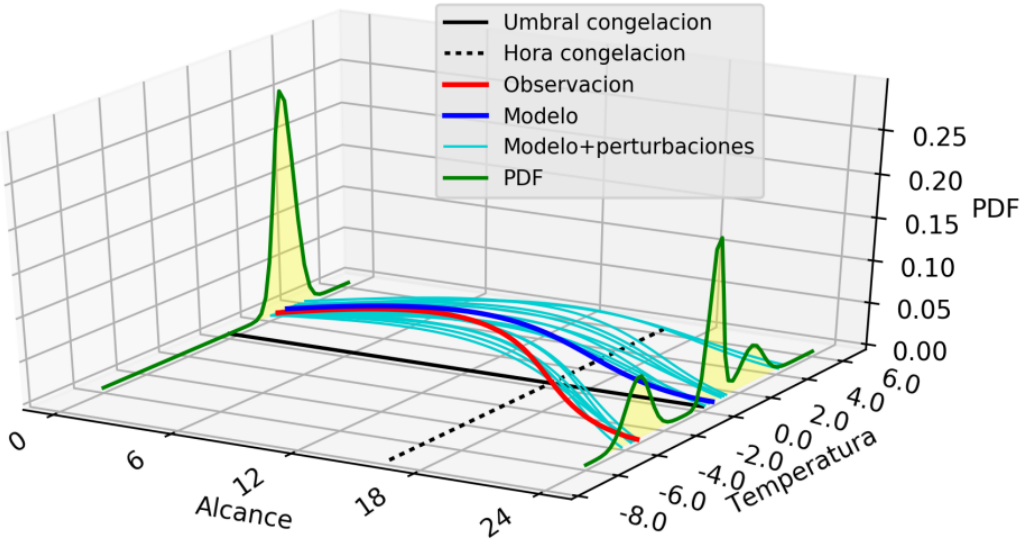

Figura 8: Evolución de la temperatura según nuestro modelo. La linea roja es la temperatura que se ha dado realmente, la azul oscuro la que nos predice nuestro modelo para el valor inicial medido con un termómetro.

En la Figura 8 se representa el modelo del que disponemos. Dado una temperatura inicial para un valor de alcance 0 obtenemos un valor, pasadas 24 horas, por encima de los cero grados y además, a lo largo de todo el tiempo ésta no bajó de los cero. Sin embargo, si observamos la line roja, que nos da el valor real, vemos que difiere bastante y en el caso de habernos fiado del modelo habriamos perdido la cosecha pues vemos que para ciertas horas la temperatura tomó valores por debajo del cero siendo a las 24 horas cercano a los -4 grados.

La linea roja de la azul no se separa demasiado para tiempo pequeños sin embargo, para tiempo más grandes ya empezamos a notar la diferencia.

Pongamos que el termómetro que utilizamos para medir la temperatura de partida, introducida en el modelo para lanzarlo, tiene una incertidumbre de $\pm 0{,}5$ grados. Podemos ahora realizar una partición del intervalo de temperaturas $[T_0 - 0{,}5; T_0 + 0{,}5]$. Tomar temperaturas en un entorno del medido y lanzar el modelo tantas veces como temperaturas diferentes tengamos. Esto nos proporcionará para cada una de las temperaturas una predicción. Las temperaturas finales no se comportarán de forma lineal, como bien sabemos ya. Es por ello que el abanico de temperaturas que obtendremos, después de correr el modelo tantas veces como hayamos partido el intervalo de temperaturas, no serán valores alrededor de un valor central. Si esto fuera así no tendría mucha gracia realizar todo este estudio pues obtendriamos siempre una densidad de probabilidad centrada en un valor, lo que viene siendo una normal, la media coincidiría con la mediana.

Como el comportamiento no es lineal, obtenemos un vector de temperaturas que se distribuirán en el espacio de estudio de tal forma que podremos obtener una distribución de las mismas y con ello extraer una función de densidad que nos proporcione información de cómo se reparten los distintos posibles escenarios y cómo de probable es que se

dé cada uno de ellos. Esto lo podemos observar en la Figura 8, en las lineas de color azul claro, se ha realizado una partición de un intervalo de temperaturas, iniciales centrada en el valor medido, y se observa que para cada una de ellas el modelo nos proporciona valores futuros de la temperatura repartidos. En el eje ortogonal al plano donde reside la temperatura y el alcance podemos observar cómo se distribuyen los distintaos valores, dibujándose la función de densidad más alta para aquellos valores que se dan con mayor frecuencia.

Una vez llegados a este punto nos es muy sencillo realizar un estudio de la incertidumbre de nuestras predicciones con un determinado modelo pues podemos hacer uso de parámetros de centralización o de dispersión como pueden ser la media, la mediana, desviación típica media o varianza entre otras. Esto mejorará considerablemente nuestra fiabilidad en las predicciones pues podremos darle más atención a aquellos escenarios en los que obtengamos mayores frecuencias. Además, gracias a esto podremos también focalizar la atención a aquellas situaciones que conlleven un riego alto para la población como pueden ser lluvias intensas, vientos fuertes o cualquier situación que pueda conllevar peligro, en resumen. Dandole una buena granularidad a nuestro intervalo de temperaturas iniciales, lo más próximo a un continuo, podremos obtener un mayor abaníco de escenarios atmosféricos posibles.

Obvio es, que a pesar del gran avance que supone realizar un estudio así a la hora de cuantificar la incertidummbre y de aumentar la calidad de nuestras predicciones, no estamos exentos de errores, los modelos seguirán teniendo errores tanto en los valores que les damos a sus parámetros como en los valores iniciales de las variables que depende pues nuestros aparatos de medida seguirán proporcionándonos errores. La ventaja de la que disponemos ahora es que este sistema de predicción nos garantiza una mayor **predecibilidad**.

Volvamos al ejemplo del huerto. Una vez obtenida una distribución de frecuencias (para un continuo sería nuestra distribución de probabilidad) definamos la media y observemos lo que ocurre,

$$\boxed{\overline{x} = \int_I x\rho(x)dx} \tag{5}$$

$$\boxed{\overline{x} = \frac{1}{\sqrt{N}}\sum_i^N x_i} \tag{6}$$

donde (5) es para el caso continuo y (6) para el caso discreto.

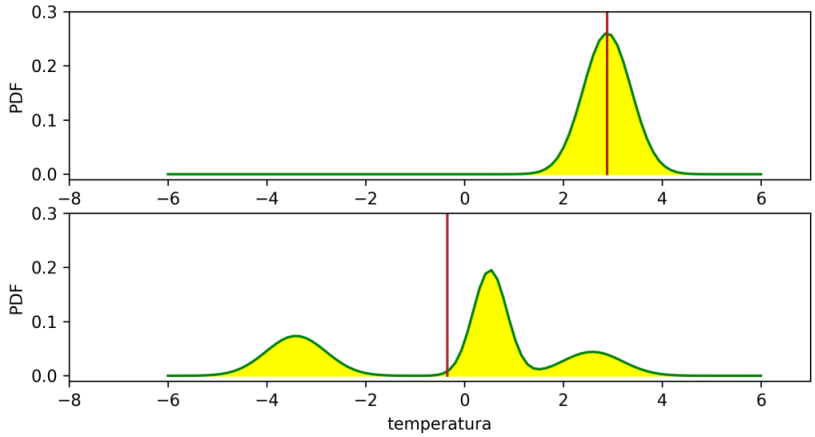

Figura 9: Se representan dos distribuciones de densidad continuas donde la linea roja representa el valor medio. La gráfica inferior es la que se discute en nuestro modelo para el huerto.

Podemos observar en la Figura 9 el valor medio de la muestra que obtenemos en el caso citado. Vemos que esta cae en un valor de temperatura que en principio tiene una probabilidad casi nula, si es que no lo es.

A la hora de realizar una predicción hay que tener cuidado pues como observamos, su valor generalmente no tiene porqué encontrarse en el espacio de estados factibles, es decir, puede que no exista ningún escenario en el que se dé el valor de la media. Para distribuciones muy simétricas la media, probablemente, tome valores dentro de los factibles pues ésta será cercana a la mediana mientras, como podemos intuir con la Figura 9, a medida que nos vayamos encontrando con distribuciones más asimétricas tendremos una mayor discrepancia entre la media y la mediana.

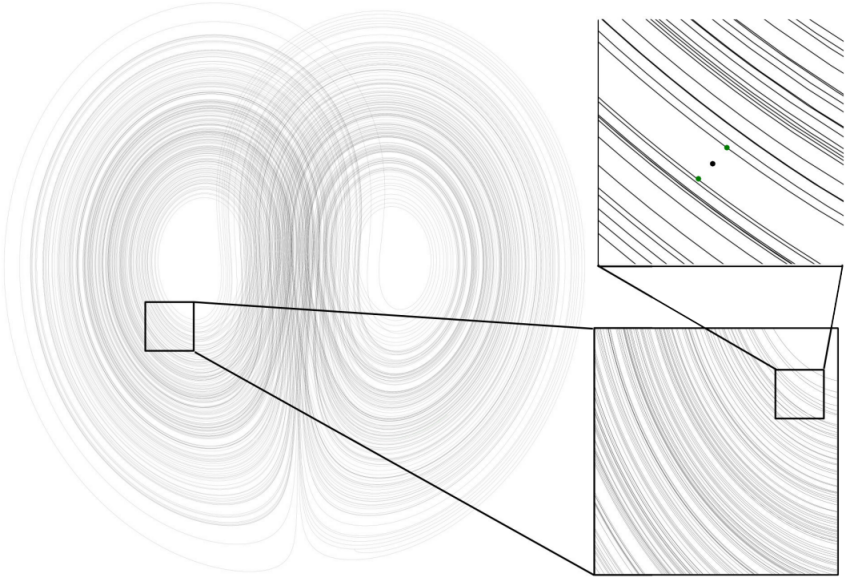

Figura 10: Se representa en un punto negro el valor medio de dos estados atmosféricos factibles en el atractor de Lorenz.

De nuevo, en la Figura 10 podemos observar lo que acabamos de decir. El valor medio de todos los escenarios obtenidos por nuestros modelos no tiene porqué caer en uno de ellos, no tiene porqué vivir en el espacio de estados atmosféricos que nos determinan la distribución de frecuencias.

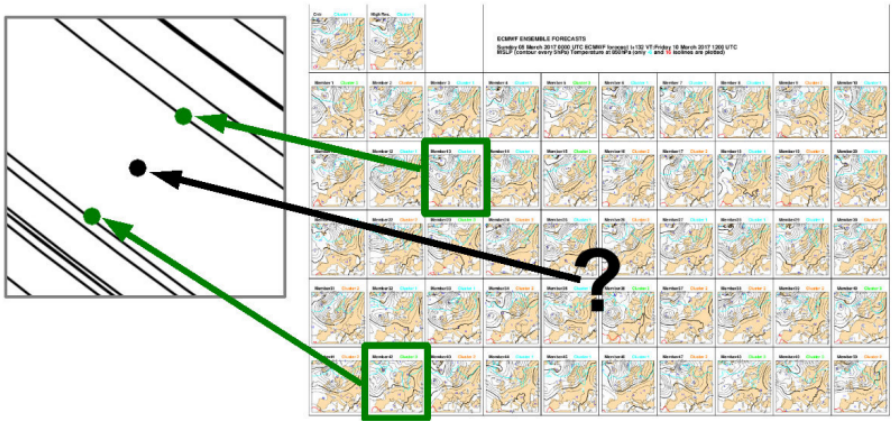

A pesar de todo esto, la media es un parámetro de centralización de enorme calidad determinista, es decir, a pesar del problema que presenta, la discrepancia que obtenemos de un escenario con dichos valores medios, es menor de la que obtendriamos al lanzar un modelo determinista en solitario. No obstante, el objetivo de construir un sistema de predicción por conjuntos no es utilizar la media como predictor.

En cuanto a la dispersión de nuestro espacio de estados, tenemos como parámetro útil la varianza o la desviación estandar,

$$\boxed{\overline{\sigma}^2 = \frac{1}{\sqrt{N-1}} \sum_{i}^{N} (x_i - \overline{x})^2} \tag{7}$$

$$\boxed{\overline{\sigma}^2 = \int_I (x_i - \overline{x})^2 \rho(x) dx} \tag{8}$$

de nuevo, la ecuación (7) es para el caso discreto y la (8) para el caso continuo.

Este parámetro nos proporciona una visión del espacio de probabilidades bastante amplia pues de él podemos extraer información varia. Por ejemplo, si obtenemos una baja dispersión, sabremos que tenemos escenarios muy cercanos a un valor medio, una distribución, más o menos, simétrica. Normalmente esta última se da cuando tenemos una atmósfera estable, en condiciones anticiclónicas. Mientras que si tenemos una gran dispersión, querrá decir que al correr diversas veces el modelo hemos obtenido una gran variedad de escenarios, en principio inconsistentes entre ellos. En este último caso nos será más complicado dar una predicción pues tendremos una baja predictibilidad.

En una distribución con una gran varianza será más viable que tengamos valores atípicos. Estos pueden ser debidos a errores y de forma general se pueden descartar. Sin embargo, antes de descartarlos hay que prestarles atención pues pueden ser valores asociados a escenarios adversos o extremos.

Una forma de desechar estos escenarios atípicos es hacer uso del rango intercuartílico, escual consiste simplemente en quedarnos con aquellos escenarios que caigan por encima del cuartil veinticinco y por debajo del setenta y cinco.

El tema da para mucho más, sin embargo, no queremos alargarnos mucho más con esto. Antes de concluir queremos hacer mención de algunos métodos que se utilizan como alternativa de los SPC. Antes de asentar los fundamentos matemáticos sobre los que descansan los SPC se hacia uso de ellos.

5.1. Consistencia entre pasadas

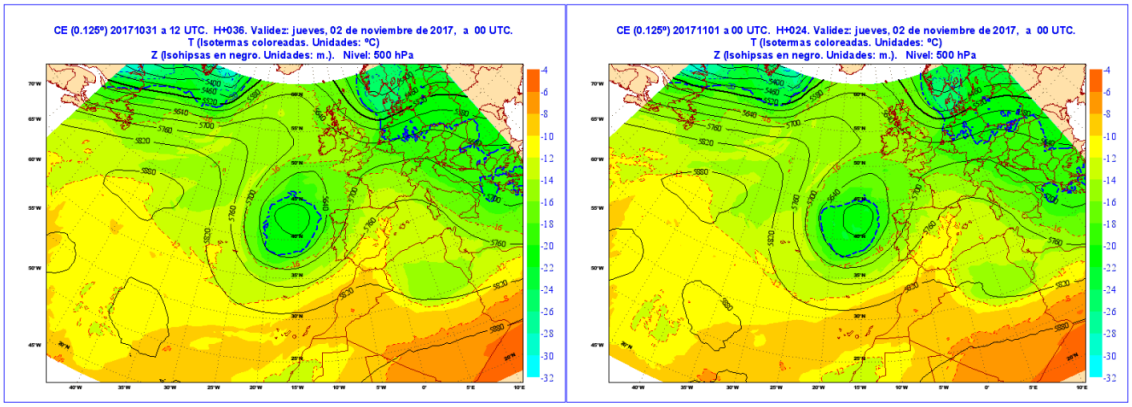

Figura 11: Dos pasadas consistentes del mismo modelo válidas para un mismo instante futuro: jueves 2 de noviembre de 2017 a las 00 UTC). Se muestran los campos de altura geopotencial y temperatura en 500 hPa. AEMET 2017

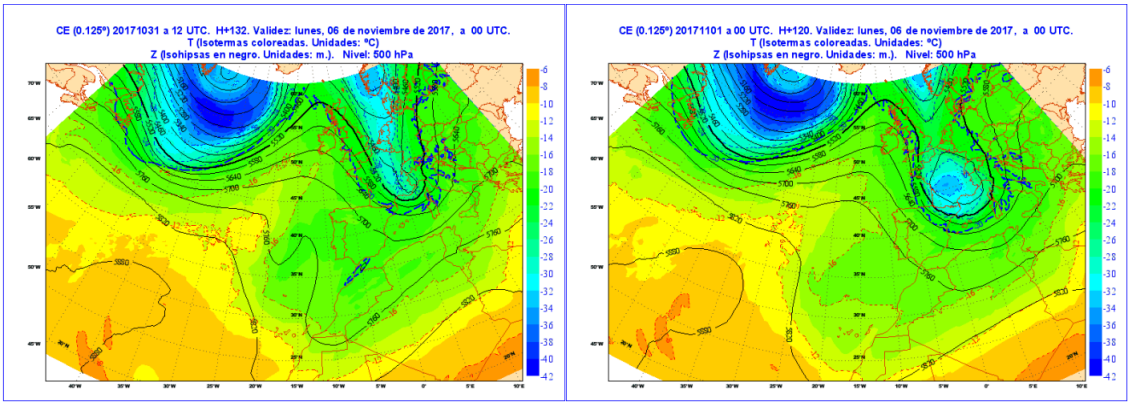

Figura 12: Dos pasadas, esta vez inconsistentes, del mismo modelo válidas para un mismo instante futuro: lunes 6 de noviembre de 2017 a las 00 UTC).

Este método consiste basicamente en correr un mismo modelo, con diferentes datos de partida, para un mismo instante futuro. Este se basa en un punto de vista más subjetivo que los SPC pues ya depende de la persona encargada la interpretación. Debe de ser él el que cuantifique de alguna manera la calidad de los resultados y lo consistente o no que pueden llegar a ser, ya que en este caso no se disponen de parámetros ni de centralización ni de dispersión con los que poder hacer un estudio de la incertidumbre.

5.2. Consistencia entre modelos

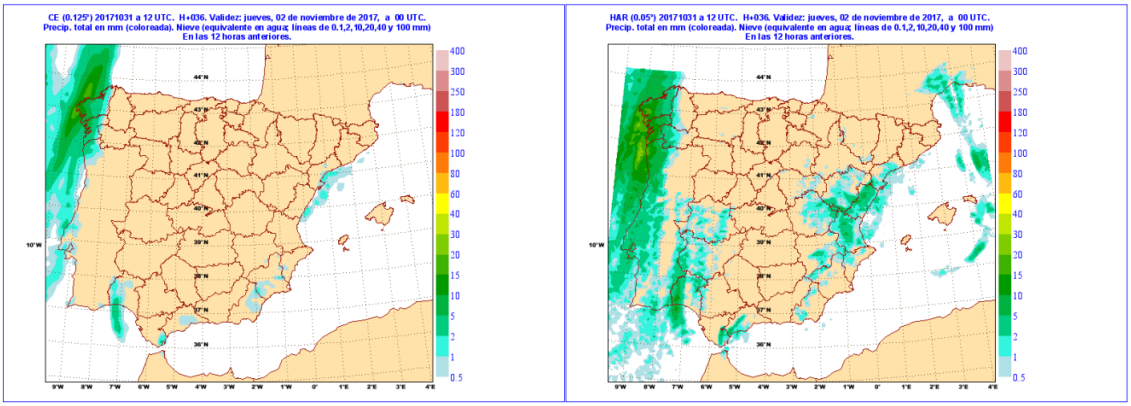

Figura 13: : Campos de precipitación acumulada de dos modelos, inconsistentes, válidos para un mismo instante futuro: jueves 2 de noviembre de 2017 a las 00 UTC). A la izquierda ECHRES y, a la derecha, HARMONIE-AROME que muestra señal consistente en Galicia pero presenta patrones en otras regiones que no ve ECHRES. AEMET 2017

La forma de proceder es muy similar a la comentada anteriormente. En este caso se hace uso de diferentes modelos y se comparan entre sí. Esto algo de gran utilidad, pues no todos los modelos se comportan igual en las mismas situaciones, incluso un determinado modelo puede mostrar discrepancias considerables ante situaciones de gran parecido entre sí. Es por ello, que realizar un análisis haciendo uso de una variedad de distintos modelos nos puede ayudar a tener una mayor predecibilidad antes los escenarios que se pueden dar. Claro es, que al igual que en el método anterior, todo queda al estudio de la persona que tenga que interpretar los resultados, es su deber realizar un análisis de los mismos. Tendrá que tener en cuenta factores como la resolución del modelo, si estos tienen en cuenta la orografía en mayor o menor medida (importante en la predicción de la precipitación), etc.

Referencias

[1] Santos Burguete, Carlos.(2018). Física del caos en la predicción meteorológica. Agencia Estatal de Meteorología. http://www.aemet.es/es/conocermas/recursos_en_linea/publicaciones_y_estudios/publicaciones/detalles/Fisica_del_caos_en_la_predicc_meteo

[2] R.Holton, James.(1990). Introducción a la meteorología dinámica. Ed. Instituto nacional de meteorología.